

یادگیری با ناظارت

یادگیری مبتنی بر نمونه (Instance-Based Learning)

المپیاد هوش مصنوعی - یادگیری ماشین

مسئله‌ای که در این بخش می‌خواهیم به آن بپردازیم این است: n داده‌ی آموزشی و m کلاس داریم و هر یک از داده‌ها متعلق به یکی از کلاس‌هاست. حال می‌خواهیم برای یک داده‌ی جدید مشخص کنیم با چه احتمالی متعلق به هر یک از کلاس‌هاست.

مثال

اگر ۳ کلاس داشته باشیم ممکن است با دیدن یک داده‌ی جدید بگوییم که این داده با احتمال ۸۰٪ برای کلاس ۱، با احتمال ۱۵٪ برای کلاس ۲، و با احتمال ۵٪ برای کلاس ۳ است.
به عبارت دیگر، می‌خواهیم یک (یا چند)تابع چگالی احتمال را از روی داده‌های آموزشی تخمین بزنیم.

• تخمین توابع چگالی دلخواه

- توابع چگالی پارامتری (مثل گوسی) معمولاً نمی‌توانند بر چگالی‌های دنیای واقعی منطبق شوند (مثلاً داده‌هایی که چند قله یا مُد دارند).
- روش‌های غیرپارامتری هیچ پیش‌فرضی درباره شکل نمودار (مثلاً زنگوله‌ای بودن) ندارند.
- روش‌های غیرپارامتری برای طبقه‌بندی:
 - روش‌های Generative: تخمین $p(x|C_i)$ (چگالی داده‌ها در هر کلاس).
 - روش‌های Discriminative: تخمین مستقیم $p(C_i|x)$ (احتمال کلاس بودن به شرط داده).

روش‌های پارامتری:

- روش‌های غیرپارامتری:
- فرض: هیچ فرضی نداریم! داده‌ها هر شکلی می‌توانند باشند.
- کار ما: نگه داشتن تمام داده‌ها.
- فاز "آموزش" خاصی نداریم؛ یادگیری در لحظه‌ی پرسش (تست) انجام می‌شود.

- فرض: داده‌ها از یک فرمول خاص (مثلاً خطی یا گوسی) پیروی می‌کنند.
- کار ما: پیدا کردن پارامترهای آن فرمول (مثلاً شب خط یا میانگین).
- پس از یادگیری، داده‌های آموزشی را دور می‌ریزیم.

در روش‌های بدون پارامتر، منطق ساده است:

«بگو دوستانت کیستند تا بگویم کیستی!»

برای تصمیم‌گیری درباره یک داده‌ی جدید (x)، به داده‌های آموزشی نزدیک به آن نگاه می‌کنیم. دو راه برای تعریف «نزدیکی» داریم:

- ❶ روش پنجره پارزن (Parzen Window): شعاع ثابتی (h) را دور x خط می‌کشیم. هر کسی داخل این شعاع بود نظر می‌دهد. (تعداد همسایه‌ها متغیر است).
- ❷ روش k نزدیک‌ترین همسایه (KNN): دقیقاً k نفر از نزدیک‌ترین افراد را پیدا می‌کنیم، فارغ از اینکه چقدر دور باشند. (شعاع همسایگی متغیر است).

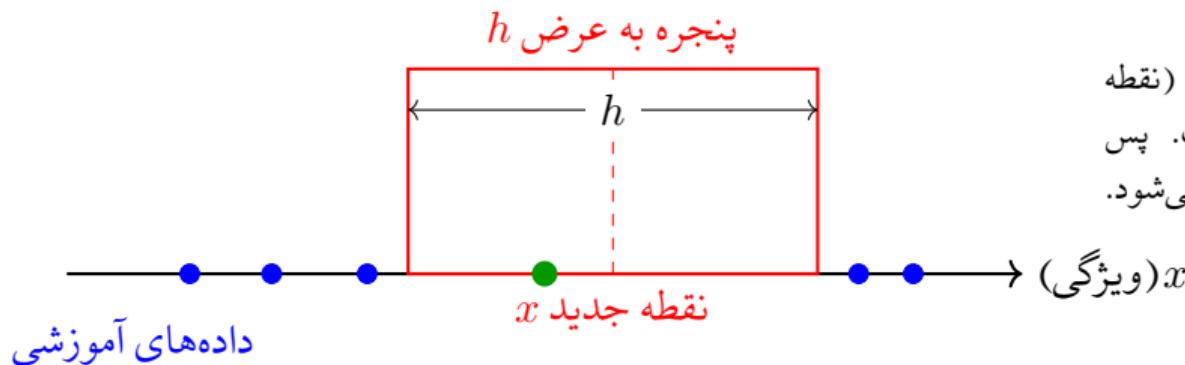
قبل از تعریف ریاضی، بایاید تصور کنیم یک پنجره (یا جعبه) داریم:

- این جعبه را دقیقاً روی داده‌ی جدید x قرار می‌دهیم.
- عرض این جعبه برابر با h است.
- هر داده‌ی آموزشی که داخل این جعبه بیفتند، یک «رأی» یا «اثر» دارد.
- مجموع این رای‌ها، چگالی (تراکم) را در نقطه x می‌سازد.

سؤال: شکل این جعبه چگونه باشد؟

- ساده‌ترین حالت: یک مستطیل تخت (ابرمکعب). هر کس داخل بود اثر ۱ دارد، هر کس بیرون بود اثر ۰.
- حالت پیشرفته (کرنل گوسی): تاثیر افراد نزدیک‌تر بیشتر از افراد دورتر است (شبیه تپه).

- تابع پنجره (کرنل) ساده: اگر فاصله داده تا مرکز کمتر از $h/2$ بود، مقدار ۱ وگرنه ۰.
- در ریاضیات، این را با یک تابع نشان می‌دهیم که اگر ورودی اش کوچک باشد ۱ می‌دهد.



شکل ۱: نمایش هندسی پنجره پارزن یک بعدی (ابرمکعب)

پارامتر h (عرض پنجره) نقش کلیدی دارد. تصور کنید می‌خواهید پستی و بلندی‌های یک تپه (تابع چگالی) را پیدا کنید:

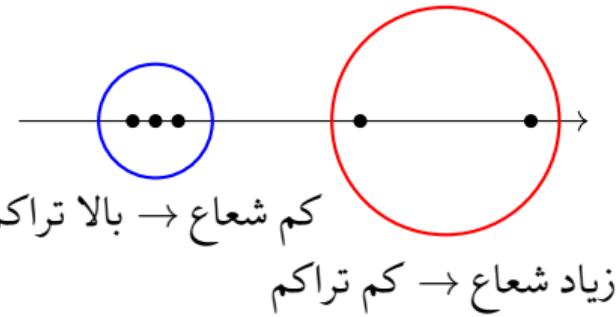
- اگر h خیلی بزرگ باشد (تار دیدن):

- پنجره آنقدر بزرگ است که همه داده‌ها را با هم قاطی می‌کند. جزئیات و قله‌های کوچک از بین می‌روند.
- نتیجه: نمودار خیلی صاف (Smooth) می‌شود.
- به زبان علمی: بایاس زیاد (چون واقعیت را ساده کرده‌ایم) و واریانس کم (با تغییر داده‌ها شکل کلی عوض نمی‌شود).

- اگر h خیلی کوچک باشد (جزئی نگری افراطی):

- پنجره فقط روی تک‌تک نقاط مرکزی می‌شود. نمودار پر از تیغه‌های باریک می‌شود.
- نتیجه: نویزهای داده به عنوان الگو شناخته می‌شوند.
- به زبان علمی: بایاس کم (دقیق روی داده‌ها) اما واریانس زیاد (حساس به نویز).

- در روش قبل h ثابت بود، اما اینجا k (تعداد همسایه) ثابت است.
- ما پنجره را آنقدر بزرگ می‌کنیم تا دقیقاً k همسایه را در بر بگیرد.
- جایی که داده‌ها متراکم هستند، پنجره کوچک می‌شود (دقت بالا).
- جایی که داده‌ها خلوت هستند، پنجره بزرگ می‌شود (دقت پایین).



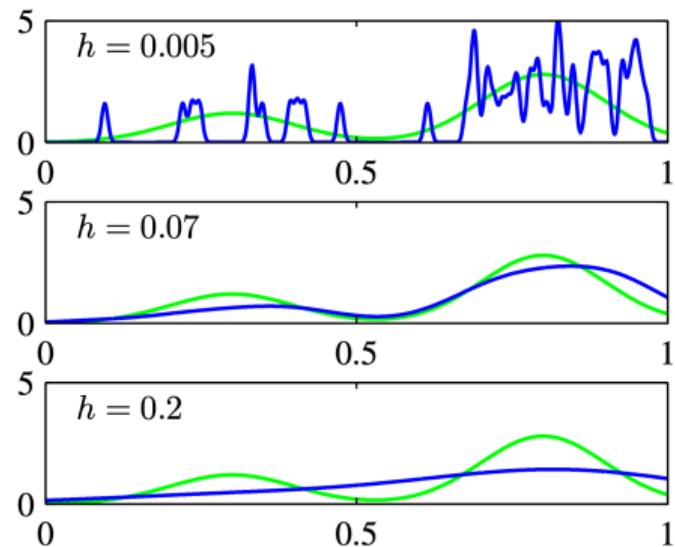
انتخاب تعداد همسایگان (k) مثل انتخاب تعداد داوران در یک مسابقه است:

- اگر $k = 1$ باشد (واریانس زیاد):
 - شما فقط به حرف نزدیکترین همسایه گوش می‌دهید.
 - اگر آن یک نفر اشتباه کرده باشد (نویز باشد)، شما هم اشتباه می‌کنید. تصمیم‌گیری بسیار متزلزل و ناپایدار است.
- اگر k خیلی بزرگ باشد (بایاس زیاد):
 - شما از کل جمعیت شهر (حتی کسانی که خیلی دورند و ربطی به شما ندارند) نظر می‌خواهید.
 - تفاوت‌های محلی از بین می‌رود و نظر اکثریت کل جامعه غلبه می‌کند. مرزهای بین کلاس‌ها محو می‌شود.
- مقدار تجربی خوب: معمولاً $\sqrt{n} = k$ پیشنهاد می‌شود.

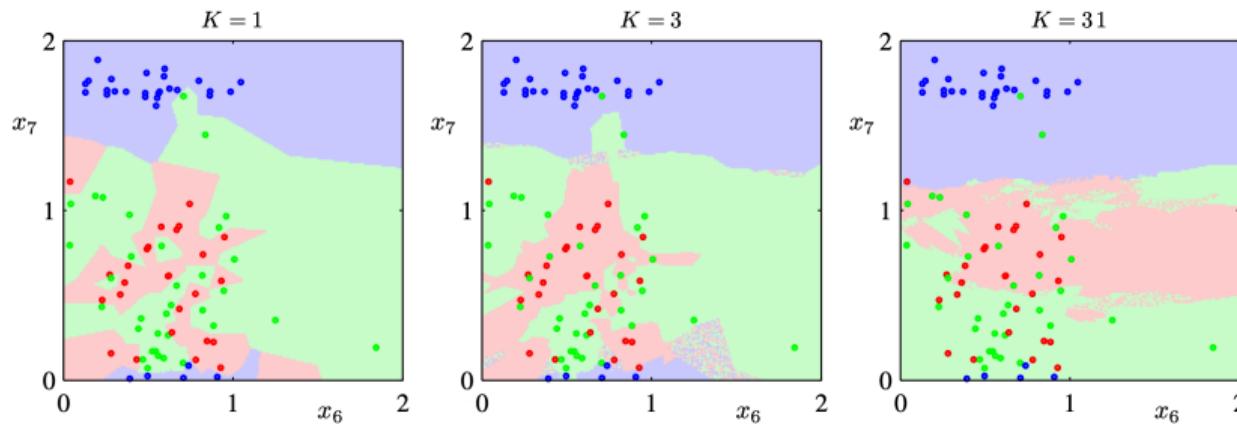
- قدرت: با داده‌ی کافی، هر تابع پیچیده‌ای را یاد می‌گیرند.
- هزینه: "تنبلی" در یادگیری باعث می‌شود در زمان تست زحمت زیادی بکشیم (محاسبات سنگین برای پیدا کردن فاصله با همه).
- نفرین ابعاد: در ابعاد بالا (تعداد ویژگی‌های زیاد)، مفهوم «فاصله» و «همسایگی» خراب می‌شود و به تعداد نمایی داده نیاز داریم.

تاثیر h (تصویری)

در شکل زیر تاثیر اندازه پنجره را می‌بینیم. به تفاوت بین "صف بودن بیش از حد" و "تیز بودن بیش از حد" دقت کنید.



شکل ۲: تاثیر h در روش پنجره‌ی پارزن



شکل ۳: مقادیر کوچک k باعث مرزهای دندانه‌دار (واریانس بالا) می‌شوند.

فاصله: چگونه شباهت را بسنجیم؟

تمام این روش‌ها بر اساس "نزدیکی" کار می‌کنند. اما نزدیکی یعنی چه؟

- معمول‌ترین روش: فاصله‌ی اقلیدسی (خط کشی).

$$d(x, x') = \sqrt{\sum_{i=1}^d (x_i - x'_i)^2}$$

- مشکل: اگر یک ویژگی عدد بزرگی باشد (مثلا حقوق به ریال) و دیگری کوچک (مثلا سن)، ویژگی بزرگ‌تر بر فاصله مسلط می‌شود.
- راه حل: استفاده از فاصله‌ی وزن‌دار یا نرمال‌سازی داده‌ها قبل از شروع کار.

$$d_w(x, x') = \sqrt{\sum_{i=1}^d w_i (x_i - x'_i)^2}$$

شما میانگین ۵ نفری هستید که بیشترین وقت را با آنها می‌گذرانید.
(جیم ران - تفسیر اجتماعی از الگوریتم KNN)

- یادگیری مبتنی بر نمونه = حافظه‌ی قوی + سنجش شباهت.
- بدون فرض اولیه (Non-parametric) = انعطاف‌پذیری بالا.
- هزینه = کندی در زمان اجرا (چون مدل فشرده‌ای نداریم).