

یادگیری بدون نظارت

خوشه‌بندی

المپیاد هوش مصنوعی - یادگیری ماشین

۱ تعریف خوشه‌بندی

۲ کاپردهای خوشه‌بندی

۳ دسته‌بندی الگوریتم‌های خوشه‌بندی

۴ روش افزایی

۵ روش سلسله مراتبی

۱ تعییف خوشه‌بندی

۲ کاپردهای خوشه‌بندی

۳ دسته‌بندی الگوریتم‌های خوشه‌بندی

۴ روشن افزایی

۵ روشن سلسله مراتبی

خوشبندی


خوش (Cluster) به گروهی از موجودیت‌ها گفته می‌شود که بیشترین شباهت را با یکدیگر دارند و از طرف دیگر بیشترین تفاوت را با موجودیت‌های قرار گرفته در خوش‌های دیگر داشته باشند. شباهت‌های موجودیت‌ها بر اساس ویژگی‌هایی که دارند و میزان نزدیکی ارتباطشان با این ویژگی‌ها در مقایسه با سایر موجودیت‌ها تعیین می‌شود.

به عنوان مثال، فرض کنید دو نقطه در یک نمودار دو بعدی داریم. با استفاده از فاصله اقلیدسی، می‌توانیم میزان نزدیکی این دو نقطه را اندازه‌گیری کنیم. به همین ترتیب، با استفاده از معیارهای شباهت مختلف، می‌توانیم میزان نزدیکی یا شباهت نقاط داده را پیدا کنیم.

تمام نقاط داده مشابه، خوش‌ها یا گروه‌ها را تشکیل می‌دهند. ایجاد این خوش‌ها به روی معنادار، خوشبندی نامیده می‌شود.

خوشبندی - ادامه

تصور کنید تعدادی شیء در یک سبد دارید. هر شکل مجموعه‌ای از ویژگی‌های مشخص (اندازه، شکل، رنگ و غیره) دارد. حال فرض کنید که از شما خواسته شده تا هریک از اشیاء را در سبد گروه‌بندی کنید. یک سوال طبیعی که باید بپرسید این است: "بر اساس چه معیاری این اشیاء را گروه‌بندی کنم؟" شاید بر اساس اندازه، شکل یا رنگ، شاید هم نه.




خوشبندی - ادامه

پاسخی که انتخاب می‌کنید ممکن است به عوامل زیادی بستگی داشته باشد، از جمله تعداد اشیاء، میزان شباهت (یا تفاوت) آنها، یا حتی سنگینی برخی از اشیاء. اصلاً واضح نیست که چه معیاری برای گروه‌بندی باید انتخاب کنید. اغلب، بهترین پاسخ این است که اشیاء را بر اساس تمام ویژگی‌هاییشان گروه‌بندی کنید. با بزرگتر شدن سبد و افزایش تعداد اشیاء، کار گروه‌بندی آنها به‌طور فزاینده‌ای پیچیده می‌شود - به همان اندازه‌ای که شیء در سبد وجود دارد، راه برای گروه‌بندی آنها وجود خواهد داشت!

به زبان ساده، الگوریتم‌های خوشبندی ابزارهای مفیدی در مدیریت سبدهای دست و پاگیر هستند.

خوش‌بندی - ادامه

نمودار زیر نحوه عملکرد الگوریتم خوش‌بندی را توضیح می‌دهد. همان‌طور که می‌بینیم، میوه‌های مختلف بر اساس ویژگی‌های مشابه، به چند گروه تقسیم شده‌اند.




خوشبندی - ادامه

در دنیای یادگیری ماشین، خوشبندی فرآیندی است که در آن انبوھی از نقاط داده بدون برچسب را بر اساس ویژگی‌هایشان به خوشبها تقسیم می‌کنیم.

- ◀ این تکنیک با پیدا کردن الگوهای مشابه مانند شکل، اندازه، رنگ یا رفتار در داده‌های بدون برچسب، آنها را بر اساس وجود یا عدم وجود این الگوها دسته‌بندی می‌کند.
- ◀ از آنجایی که خوشبندی یک روش یادگیری بدون نظارت است، هیچ اطلاعات از پیش تعیین شده‌ای در اختیار الگوریتم قرار نمی‌گیرد و الگوریتم مستقیماً با داده‌های بدون برچسب کار می‌کند.
- ◀ پس از انجام خوشبندی، به هر خوشبندی یک گروه یک شناسه اختصاص داده می‌شود. سیستم‌های یادگیری ماشین می‌توانند از این شناسه‌ها برای آسان‌تر کردن پردازش مجموعه‌های داده‌های بزرگ و پیچیده استفاده کنند.

خوشه‌بندی - ادامه



هدف خوشه‌بندی

- ◀ مرحله پیش‌پردازش برای نمایه‌سازی، فشرده‌سازی یا کاهش داده‌ها
- ◀ نمایش داده‌های با ابعاد بالا در فضای با ابعاد پایین (به عنوان مثال، برای مقاصد بصری)
- ◀ کشف دانش از داده‌ها: به عنوان ابزاری برای درک ساختار پنهان در داده‌ها یا گروه‌بندی آن‌ها
- ◀ کسب بینش در مورد ساختار داده‌ها (قبل از طراحی طبقه‌بند)
- ◀ فراهم کردن اطلاعات در مورد ساختار داخلی داده‌ها
- ◀ برای گروه‌بندی یا تقسیم داده‌ها زمانی که برچسبی در دسترس نیست

۱ تعریف خوشه‌بندی

۲ کاپردهای خوشه‌بندی

۳ دسته‌بندی الگوریتم‌های خوشه‌بندی

۴ روش افزاری

۵ روش سلسله مراتبی

کاربردهای خوشبندی



دربیافت اطلاعات (جستجو و مرور)

- خوشبندی مستندات متنی یا تصاویر بر اساس محتوای آنها
- خوشبندی گروههای کاربران بر اساس الگوهای دسترسی آنها به صفحات وب
- خوشبندی کاربران شبکه‌های اجتماعی بر اساس علایق (شناسایی جامعه).
- بیوانفورماتیک


- خوشبندی پروتئین‌های مشابه با هم (شبیه‌سازی از نظر ساختار شیمیایی و/یا عملکرد و غیره) یا ژن‌های مشابه بر اساس داده‌های میکروواری
- تقسیم‌بندی بازار

- خوشبندی مشتریان بر اساس تاریخچه خرید و ویژگی‌های آنها
- تقسیم‌بندی تصویر
- و بسیاری از کاربردهای دیگر

مثال‌هایی از کاربردهای خوشه‌بندی



(ب) تقسیم‌بندی تصویر



(ج) خوشه‌بندی ژن‌های مشابه

۱ تعریف خوشه‌بندی

۲ کاپردهای خوشه‌بندی


۳ دسته‌بندی الگوریتم‌های خوشه‌بندی

۴ روش افزایی


۵ روش سلسله مراتبی

الگوریتم‌های خوش‌بندی

الگوریتم‌های خوش‌بندی را می‌توان به دو دسته افزایی و سلسله‌مراتبی دسته‌بندی کرد.



(ه) روش سلسله‌مراتبی



(د) روش افزایی

۱ تعریف خوشه‌بندی

۲ کاپردهای خوشه‌بندی

۳ دسته‌بندی الگوریتم‌های خوشه‌بندی

۴ روش افزایی

۵ روش سلسله مراتبی


روش افزایی

در این روش، هدف این است که یک مجموعه داده را به K خوش مختلط تقسیم کنیم، بطوریکه:

- ◀ هر داده به طور دقیق در یکی از K خوشهای که با هم هیچ اشتراکی ندارند، قرار می‌گیرد.
- ◀ تمام داده‌های موجود در مجموعه داده باید در یکی از این K خوشه قرار بگیرند. به عبارت دیگر، اجتماع تمام خوشه‌ها برابر با کل مجموعه داده است.
- ◀ هیچ دو خوشه‌ای نباید عضو مشترک داشته باشند. این به این معنی است که هر داده فقط می‌تواند به یک خوشه تعلق داشته باشد. این نوع افزایش بندی به عنوان خوشبندی سخت نیز شناخته می‌شود، جایی که هر داده فقط به یک خوشه تعلق دارد.
- ◀ از آنجایی که خروجی این روش فقط یک مجموعه از خوشه‌ها است، کاربر باید از قبل تعداد خوشه‌های مورد نظر (K) را مشخص کند.


k-means الگوریتم

K-means یکی از محبوب‌ترین و پرکاربردترین الگوریتم‌ها در دسته‌ی الگوریتم‌های افزایی است.




الگوریتم K-means برای پردازش داده‌های آموزشی، کار خود را با یک گروه اولیه از مراکز خوش‌آغاز می‌کند. این مراکز به عنوان نقاط شروع برای هر خوش‌بندی مورد استفاده قرار می‌گیرند و سپس الگوریتم محاسبات تکراری انجام می‌دهد تا موقعیت این مراکز را بهینه کند. در ادامه هریک از گام‌ها به ترتیب توضیح داده شده است.

ابتدا به صورت تصادفی تعدادی نقطه را به عنوان مرکز اولیه برای هر خوش‌بندی انتخاب می‌کنیم (تعداد این نقاط همان K است که از قبل مشخص کردہ‌ایم). مثل اینکه چند میخ را به صورت تصادفی روی صفحه قرار دهیم.




گام دوم

هر نقطه از داده‌ها را به نزدیک‌ترین مرکزی که انتخاب کردہ‌ایم نسبت می‌دهیم. مثل اینکه با یک نخ، هر نقطه را به نزدیک‌ترین میخ وصل کنیم. به این ترتیب، نقاط در اطراف هر مرکز، یک خوش‌های را تشکیل می‌دهند.




گام سوم

حالا برای هر خوش، مرکز جدید را محاسبه می‌کنیم. این مرکز جدید، میانگین تمام نقاطی است که در آن خوش قرار دارند. مثل اینکه جای میخ‌ها را به وسط مجموعه‌ای از نقاطی که به آن وصل شده‌اند، تغییر دهیم.




گام چهارم

گام‌های دوم و سوم را دوباره تکرار می‌کنیم. یعنی دوباره هر نقطه را به نزدیک‌ترین مرکز جدید نسبت می‌دهیم و سپس مراکز جدید را محاسبه می‌کنیم. این کار را آنقدر ادامه می‌دهیم تا دیگر جای مراکز تغییر نکند یا تغییرات بسیار کم شود.



روش انتخاب بهینه مقدار K

تصور کنید می‌خواهید یک دسته از افراد را در چند گروه دسته‌بندی کنید. هرچه تعداد گروه‌ها بیشتر باشد، افراد داخل هر گروه شبیه‌تر خواهند بود (خطای کمتری داریم). اما اگر تعداد گروه‌ها خیلی زیاد شود، ممکن است گروه‌های خیلی کوچکی تشکیل شوند که دیگر معنی خاصی ندارند. بنابراین در گام اول الگوریتم k-means کجا مطمئن باشیم که چند خوش باید تولید شود؟



نقطه آرنج

نقطه آرنج (Elbow Point) یک روش بصری است که برای پیدا کردن تعداد بهینه خوشها (مقدار مناسب K در الگوریتم K-means) استفاده می‌شود. به این صورت کار می‌کند:


- ◀ شما الگوریتم K-means را چندین بار اجرا می‌کنید، هر بار با تعداد خوشها م مختلف (مثلاً از ۱ تا ۱۰).
- ◀ برای هر تعداد خوشهای که امتحان می‌کنید، یک معیار به نام مجموع مربعات خطای محاسبه می‌کنید. این معیار نشان می‌دهد که چقدر نقاط داده در داخل هر خوشی در مرکز آن خوش نزدیک هستند. هرچه این مقدار کمتر باشد، خوشبندی بهتر انجام شده است.
- ◀ حالا شما یک نمودار رسم می‌کنید که در محور افقی آن تعداد خوشها (K) و در محور عمودی آن مقدار SSE قرار دارد.

نقطه آرنج

پیدا کردن آرنج: در این نمودار، معمولاً یک منحنی می‌بینید که با افزایش تعداد خوشبندی، مقدار SSE کاهش پیدا می‌کند. در ابتدا، این کاهش خیلی سریع است، اما بعد از یک نقطه، شیب منحنی کم می‌شود و کاهش SSE کندرتر می‌گردد. به نقطه‌ای در این نمودار که این تغییر شیب ناگهانی رخ می‌دهد، "نقطه آرنج" می‌گویند، چون شکل نمودار در آن نقطه شبیه آرنج خشمده به نظر می‌رسد.

انتخاب K بهینه: مقدار K در نقطه آرنج، معمولاً به عنوان تعداد بهینه خوشبندی در نظر گرفته می‌شود. دلیلش این است که قبل از این نقطه، افزایش تعداد خوشبندی باعث کاهش چشمگیر خطا می‌شود، اما بعد از این نقطه، افزودن خوشبندی‌های بیشتر تاثیر چندانی در کاهش خطا ندارد و ممکن است باعث ایجاد خوشبندی‌هایی شود که خیلی معنی‌دار نیستند.

نقطه آرنج



۱ تعریف خوشه‌بندی

۲ کاپردهای خوشه‌بندی

۳ دسته‌بندی الگوریتم‌های خوشه‌بندی

۴ روش افزایی

۵ روش سلسله مراتبی

روش سلسله مراتبی

خوشبندی سلسله مراتبی یک روش دیگر برای گروه‌بندی داده‌ها است که بخلاف روش افزایی، نیازی به تعیین تعداد خوشه‌ها از قبل ندارد. در عوض، این روش یک ساختار درختی از خوشه‌ها ایجاد می‌کند که نشان می‌دهد خوشه‌ها چگونه با یکدیگر ارتباط دارند.

تصور کنید می‌خواهید یک دسته از اشیاء را بر اساس شباهت‌هایشان دسته‌بندی کنید، مثل دسته‌بندی جانوران. شما ممکن است ابتدا آن‌ها را به گروه‌های بزرگتر مثل پستانداران، پرندگان، خزندگان و غیره تقسیم کنید.

سپس هر کدام از این گروه‌ها را به گروه‌های کوچکتر تقسیم کنید، مثلاً پستانداران را به سگ‌سانان، گربه‌سانان و غیره. این یک نوع ساختار سلسله مراتبی است.


روش سلسله مراتبی



روش ادغام شونده

روش ادغام شونده (Agglomerative Clustering) از پایین به بالا کار می‌کند. یعنی ابتدا هر داده به عنوان یک خوشه جداگانه در نظر گرفته می‌شود. سپس، در هر مرحله، نزدیک‌ترین خوشه‌ها با هم ادغام می‌شوند تا اینکه در نهایت همه داده‌ها در یک خوشه بزرگ قرار بگیرند. مثل این است که شما از تک‌تک برگ‌های یک درخت شروع کنید و آن‌ها را به شاخه‌های کوچک، سپس به شاخه‌های بزرگ‌تر و در نهایت به تنه درخت وصل کنید.

Agglomerative Clustering



روش تقسیم شونده

روش تقسیم شونده (Divisive Clustering) از بالا به پایین کار می‌کند. یعنی ابتدا همه داده‌ها در یک خوشه بزرگ قرار دارند. سپس، در هر مرحله، این خوشه به خوشه‌های کوچکتر تقسیم می‌شود تا اینکه هر داده به یک خوشه جداگانه تبدیل شود. مثل این است که شما از کل یک درخت شروع کنید و آن را به شاخه‌های اصلی، سپس به شاخه‌های کوچکتر و در نهایت به برگ‌ها تقسیم کنید.

